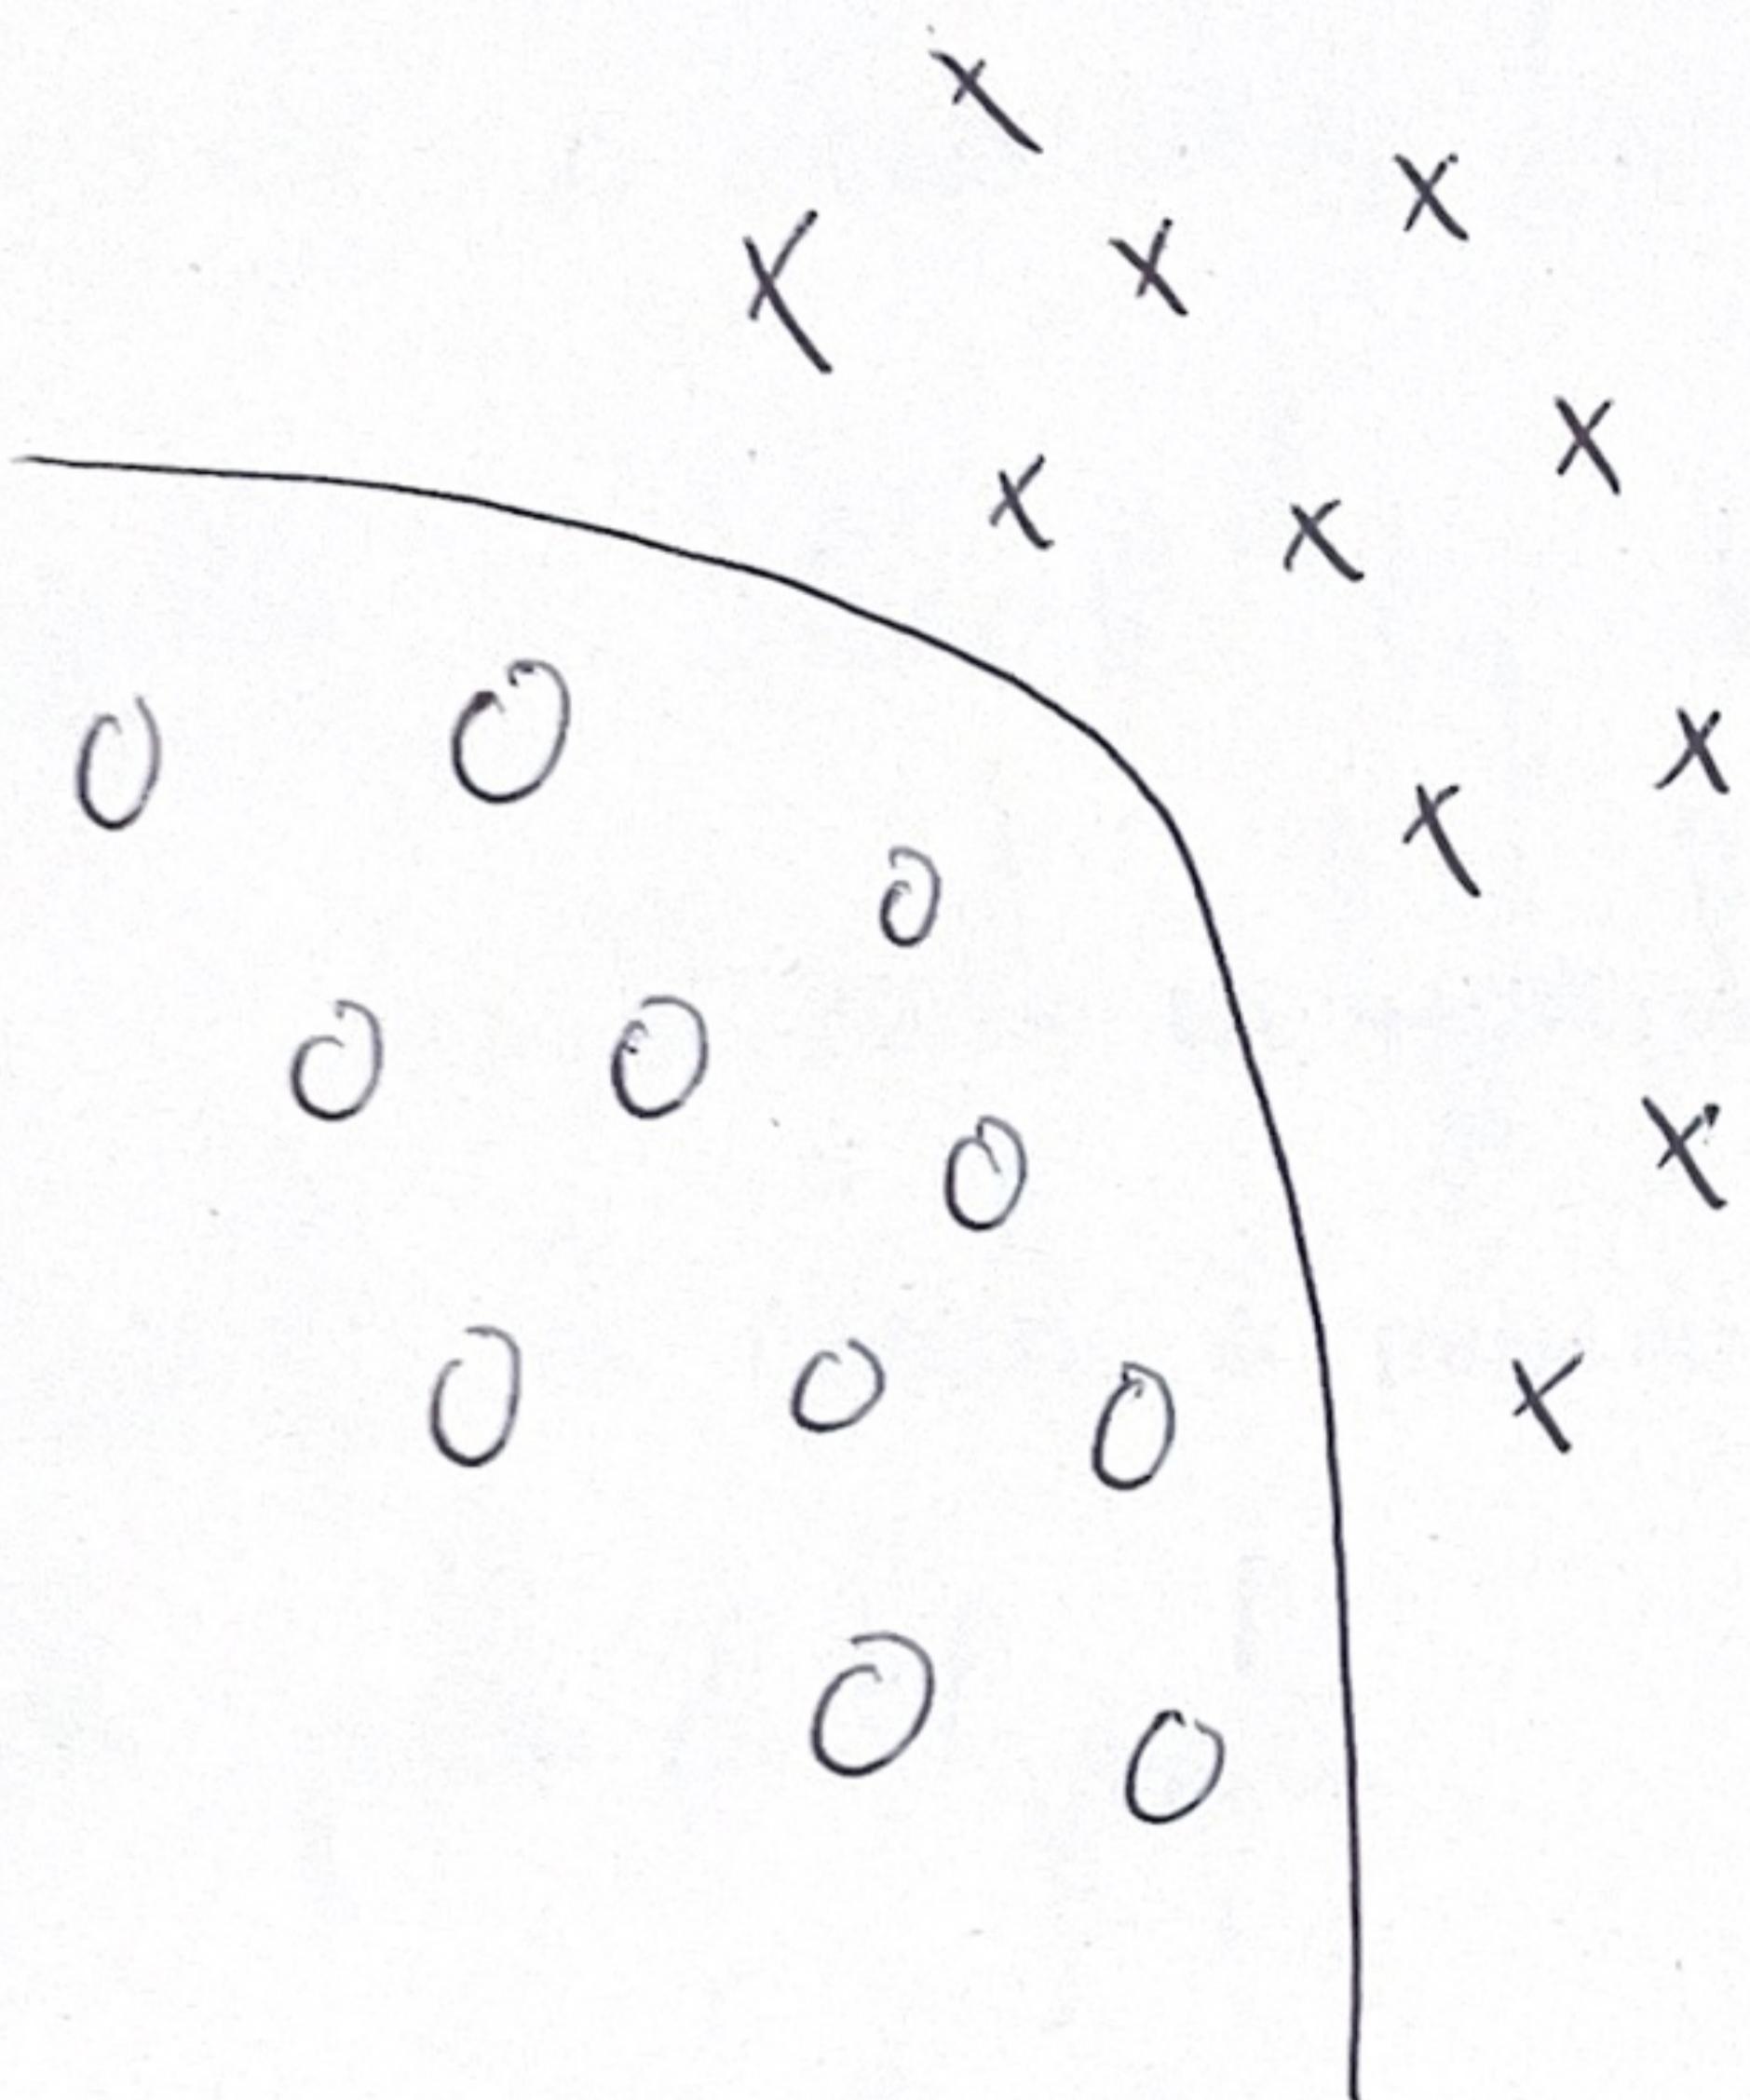


①

## Lesson n° 6: Méthodes à noyaux II



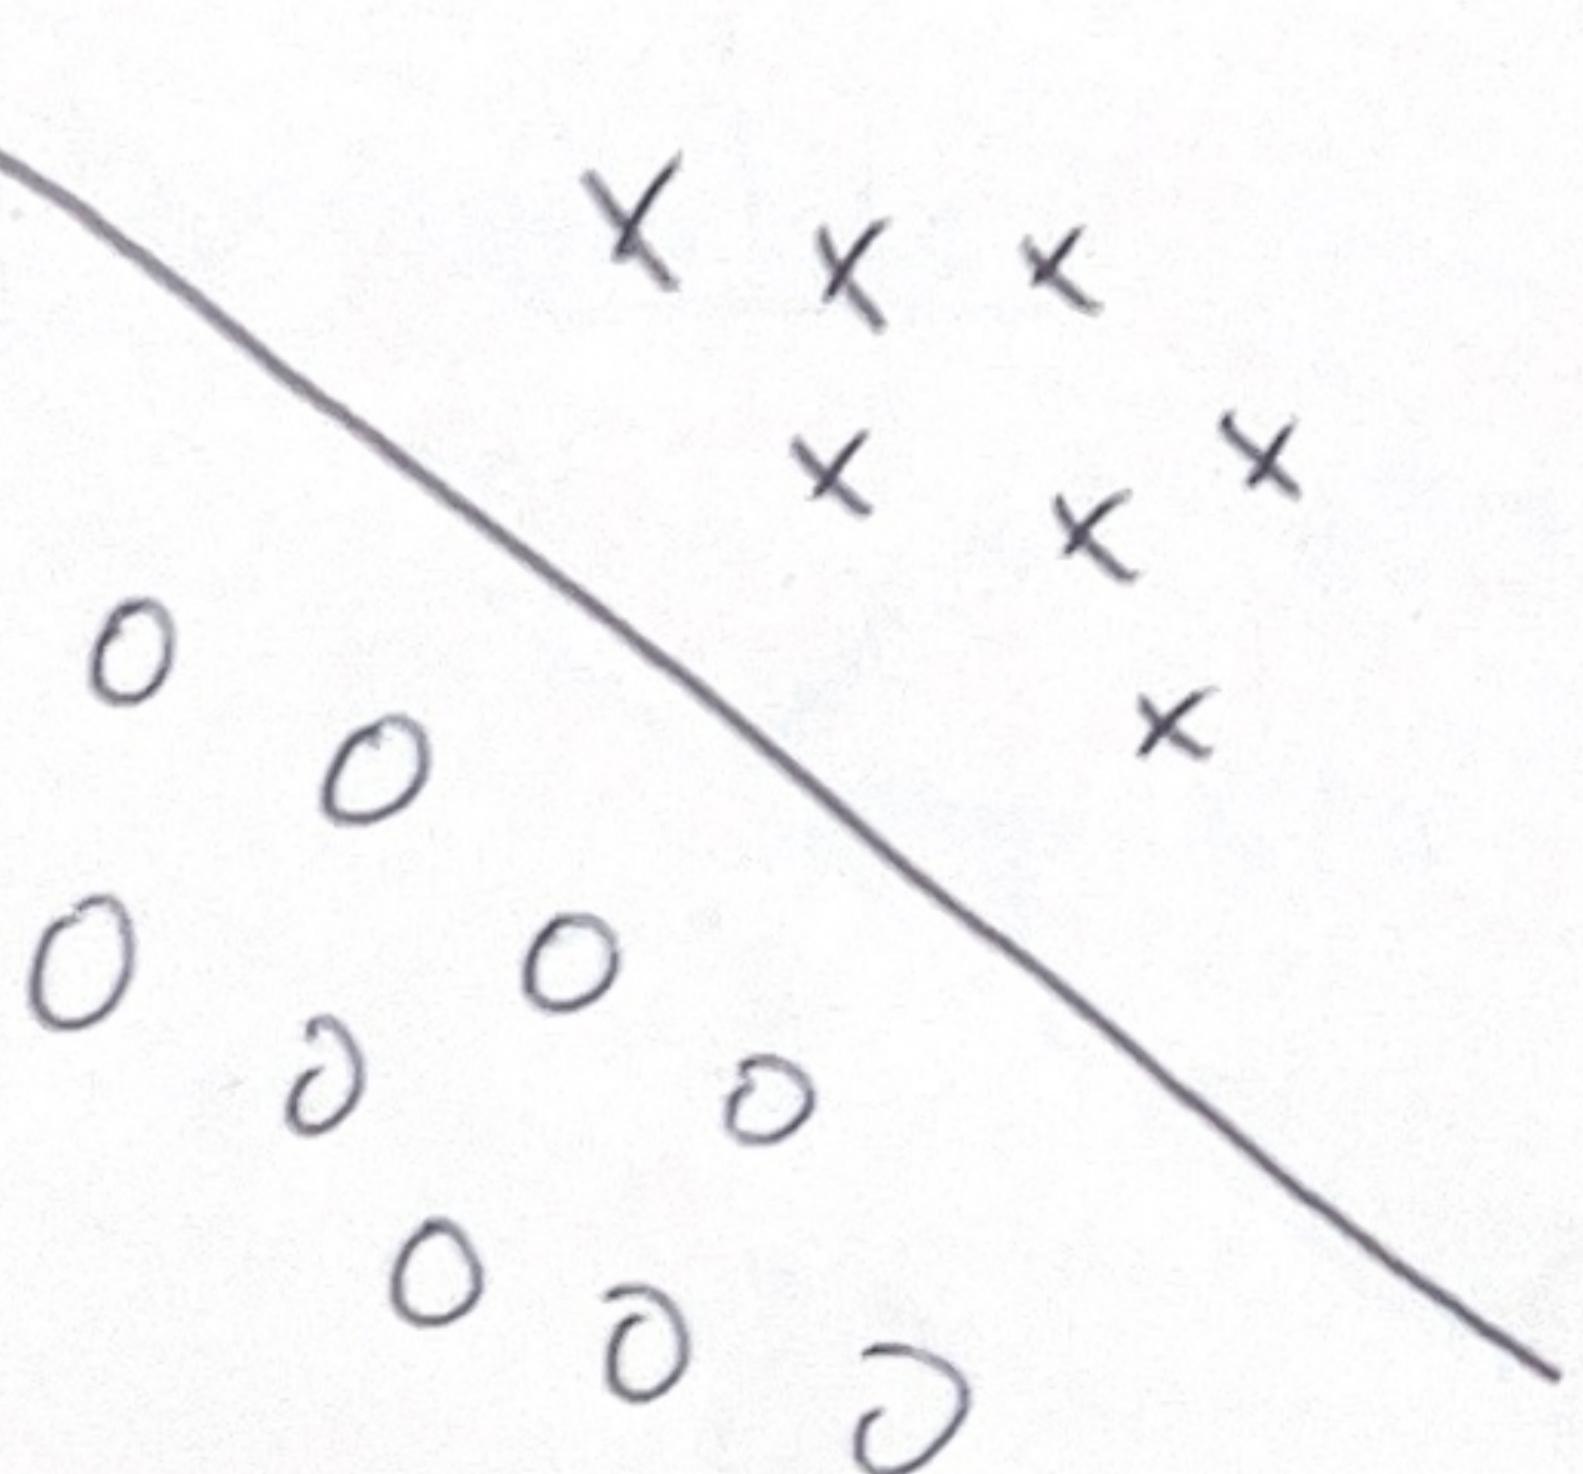
Objectif: Séparer deux classes

Problème:  $\hat{\theta} \in \arg\min_{\theta} \frac{1}{n} \sum_{i=1}^n \max(1 - y_i(\langle \theta, \phi(x_i) \rangle), 0) + \frac{\lambda}{2} \|\theta\|^2$

↳ Minimum du risque empirique pour la fonction de perte

~~Hinge~~ + Regularisation.

### I. Le cas linéaire séparable



②

~~Hypothèse~~

Contexte n observations  $(x_i, y_i) \in \mathbb{R}^d \times \{-1, 1\}$

Hypothèse:  $\exists \theta \in \mathbb{R}^d \text{ t.q. } \forall i, y_i (\theta^T x_i) \geq 0$

$\hookrightarrow$  Il existe un hyperplan séparateur.

Objectif: On cherche à maximiser la distance du point le plus proche de l'hyperplan.

Expression de la distance Soit  $H(\theta)$  l'hyperplan d'équation  $\theta^T x = 0$ .

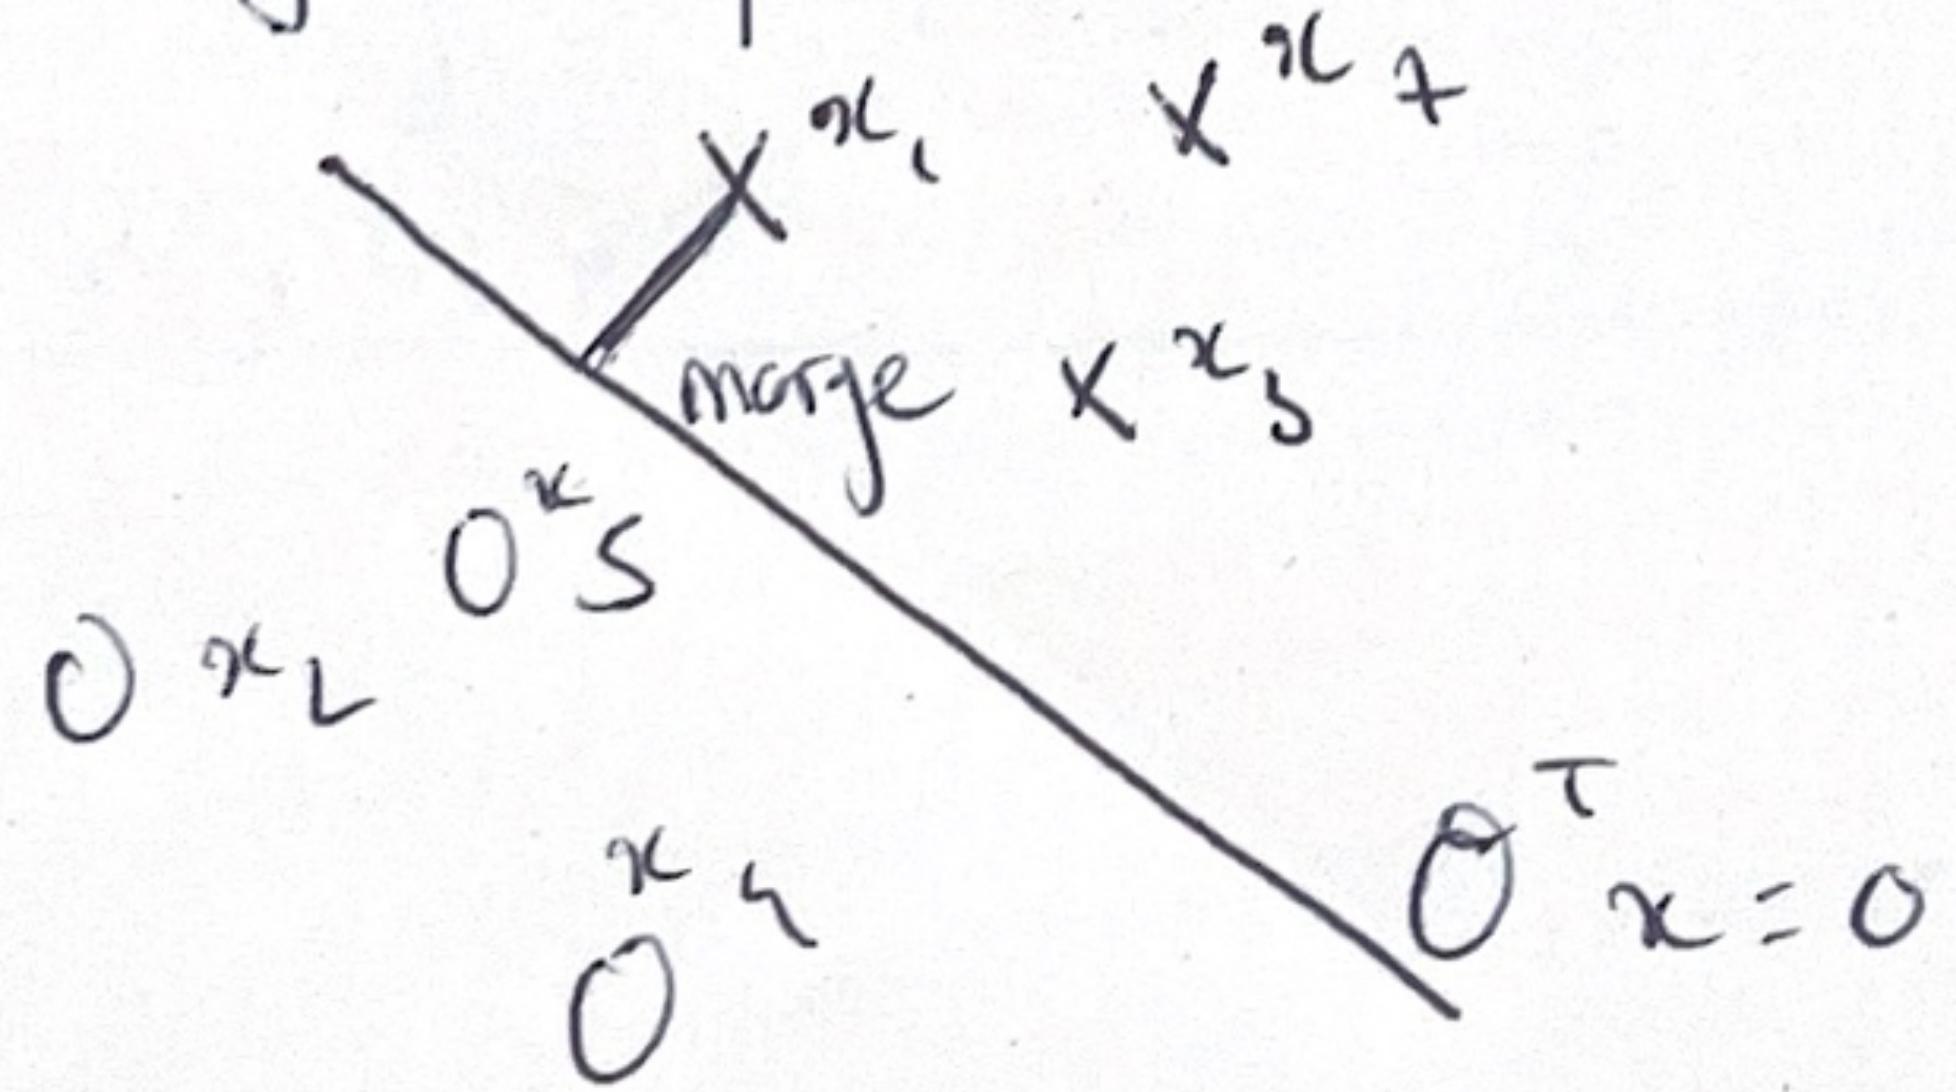
$$\text{alors, } \forall x, \text{dist}(x, H(\theta)) = \frac{|\theta^T x|}{\|\theta\|_2}$$

$$\hookrightarrow \text{en effet, } \text{dist}(x, H(\theta))^2 = \|x - P_{H(\theta)}(x)\|^2$$

$$= \left\| \left( \frac{\theta}{\|\theta\|_2} \right)^T x \right\|^2$$

base orthonormée de  $H(\theta)^\perp$ .

Interprétation géométrique:



③

### Marge la plus grande possible

$$\underset{\theta \text{ sépare tous les points}}{\text{Max}} \min_{i \in \{1, \dots, n\}} \frac{y_i (\theta^T x_i)}{\|\theta\|_2}$$

ce qui est équivalent à

$$\min_{\theta} \frac{1}{2} \|\theta\|_2^2 \text{ tq } \forall i, y_i (\theta^T x_i) \geq 1$$

### II - Cas Linéaire non séparable

Dans le cas où le problème n'est pas linéairement séparable (ie  $\forall \theta, \exists i \text{ tq } y_i (\theta^T x_i) \leq 0$ ), il est possible d'introduire des variables mesurant la sous-optimalité de chaque contrainte

$$\begin{aligned} & \min_{\theta, \xi} \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^n \xi_i \\ & \text{tq } \forall i, y_i (\theta^T x_i) \geq 1 - \xi_i \\ & \quad \xi_i \geq 0 \end{aligned}$$

④

et en notant  $\lambda = \frac{1}{nC}$  et  $\xi_i = (1 - y_i(\theta^T x_i))_+$ , le problème est équivalent à

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n \xi_i + \frac{\lambda}{2} \|\theta\|_2^2$$

### III - ~~Dual problem~~ Problème dual

primal:

$$\begin{aligned} & \min_{\theta, \xi} \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^n \xi_i \\ & \text{tg } \forall i, y_i \cdot \theta^T x_i + \xi_i - 1 \geq 0 \\ & \forall i, \xi_i \geq 0 \end{aligned}$$

problème convexe à contraintes linéaires.

Lagrangien (multiplicateurs de Lagrange  $\alpha_1, \dots, \alpha_n, \beta_1, \dots, \beta_n \geq 0$ )

$$L = \frac{1}{2} \|\theta\|_2^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i (y_i \cdot \theta^T x_i + \xi_i - 1) - \sum_{i=1}^n \beta_i \xi_i$$

\* Minimisation par rapport à  $\xi_1, \dots, \xi_n$ :

Le lagrangien est égal à  $-\infty$  si  $\exists i: \alpha_i \neq 0 \wedge \beta_i \neq 0$ ,  
et dans ce cas les termes en  $\xi$  disparaissent.

⑤

\* Minimisation par rapport à  $\theta$ :

$$\text{Forme close } \hat{\theta}^* = \sum_{i=1}^n d_i g_i x_i$$

Donc le problème dual est

$$\left\{ \begin{array}{l} \text{max}_{\alpha, \beta} \quad \sum_{i=1}^n d_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j g_i g_j x_i^T x_j \\ \alpha \geq 0, \beta \geq 0 \\ \text{s.t. } \alpha_i + \beta_i = C \end{array} \right.$$

ce qui est équivalent à

$$\text{max}_{\alpha} \quad \sum_{i=1}^n d_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j g_i g_j x_i^T x_j$$

$$\alpha \geq 0$$

$$\text{s.t. } 0 \leq \alpha_i \leq C$$

Problème dual

Par dualité faible      Dual  $\leq$  Primal

Condition de Slater: IP possède des points strictement réalisables

donc la condition de Slater s'applique  $\Rightarrow$  IP g a dual faible

⑥

Donc Primal = Dual

et le dual est un problème de programmation quadratique à contraintes de type "boîte".

### III La version avec noyaux

Soit  $H$  un espace de Hilbert et  $\phi: X \rightarrow H$ .

Soit  $K: X \times X \rightarrow \mathbb{M}$

$$x, y \mapsto \langle \phi(x), \phi(y) \rangle_H$$

(D'après le théorème d'Aronszajn, les deux définitions  
sont équivalentes)

Problème:  $\hat{\phi}_y \in \arg \min_{\phi \in H} \sum_{i=1}^n (1 - y_i \langle \phi, \phi(x_i) \rangle_H)^+ + \frac{\lambda}{2} \|\phi\|_H^2$

### Théorème de représentation:

IP faut chercher  $\hat{\phi}_y$  de la forme  $\alpha_1 \phi(z_1) + \dots + \alpha_n \phi(z_n)$ ,

ce qui équivaut à chercher une fonction de classification

$$\text{de la forme } x \mapsto \operatorname{sgn} (\alpha_1 \langle \phi(z_1), \phi(x) \rangle + \dots + \alpha_n \langle \phi(z_n), \phi(x) \rangle)$$

⑦

## Méécriture du problème:

$$\underset{\alpha}{\text{margin}} \hat{=} \frac{1}{n} \sum_{i=1}^n (1 - g_i(K\alpha))_+ + \frac{\gamma}{2} \alpha^T K \alpha$$

où  $K = (K(x_i, x_j))_{i,j}$

## Introduction des variables "Slack"

$$\min_{\alpha, \xi} \frac{1}{n} \sum_{i=1}^n \xi_i + \frac{\gamma}{2} \alpha^T K \alpha$$

$$\text{tq } \forall i, \xi_i \geq 1 - g_i(K\alpha)_+$$

$$\forall i, \xi_i \geq 0$$

Lagrangien:  $\mu, \nu \geq 0$  multiplicateurs de Lagrange.

$$L = \frac{1}{n} \sum_{i=1}^n \xi_i + \frac{\gamma}{2} \alpha^T K \alpha - \sum_{i=1}^n \mu_i (y_i (K \alpha)_i + \xi_i - 1) - \sum_{i=1}^n \nu_i \xi_i$$

$$= \frac{1}{n} \sum_{i=1}^n \xi_i + \frac{\gamma}{2} \alpha^T K \alpha - (\text{diag}(\mu) \nu)^T K \alpha - (\mu + \nu)^T \xi + \mu^T \mathbf{1}$$

② Minimisation en  $\alpha$   $\Rightarrow \alpha = \frac{\text{diag}(y)\mu}{\|y\|} + \varepsilon$  avec  $\varepsilon \in \text{Ker}(k)$   
 Mais comme ça ne change rien, on peut prendre  $\varepsilon = 0$ .

Minimisation en  $\{g\}$   $\Rightarrow -\infty$  si  $\frac{1}{n} - \mu - \nu \neq 0$   
 et tous les termes en  $\{g\}$  disparaissent sinon.

d'où

Problème dual :  $\left\{ \begin{array}{l} \text{max } \sum_{i=1}^n p_i - \frac{1}{2} \sum_{i,j=1}^n g_i g_j p_i p_j K(x_i, x_j) \\ \text{tq } p \geq 0, \nu \geq 0, \mu + \nu = \frac{1}{n} \end{array} \right.$

ou encore :

$\text{max } \sum_{i=1}^n p_i - \frac{1}{2} \sum_{i,j=1}^n g_i g_j p_i p_j K(x_i, x_j)$   
 tq  ~~$p \geq 0$~~   $0 \leq p \leq \frac{1}{n}$

problème dual |

⑨

## Reformulation avec variables primales

D'après (1), il est possible de reformuler le problème dual à l'aide de  $\alpha$ :

$$\boxed{\begin{array}{ll} \text{max}_{\alpha} & 2 \alpha^T y - \alpha^T K \alpha \\ \text{s.t.} & t_y \leq y \alpha \leq \frac{1}{\alpha_n} \end{array}}$$

Et encore une fois, il y a dualité parfaite pour les mères scissées.