

## Contrôle Terminal

Le contrôle est composé de trois exercices indépendants et est noté sur 20 points. Si un ajustement est nécessaire, votre note finale ne sera pas inférieure à celle calculée en faisant simplement la somme des points.

Ici  $\log$  est le logarithme népérien.

### Exercice 1

Un sondage a recueilli des informations sur le prix (au kilogramme) de certains fruits et légumes. Le tableau suivant donne les effectifs pour chaque paire type / classe de prix.

	pomme	poire	courgette	aubergine
2 €	12	24	54	23
3 €	45	26	72	16
4 €	34	63	34	33

Par exemple, dans le sondage il y a 12 pommes qui coutent 2 € (au kilogramme).

- 1) (1 point) Calculer la probabilité que le fruit/légume du sondage soit une pomme sachant que son prix est 3 € (Avec justification).
- 2) (1 point) Calculer la probabilité que le fruit/légume du sondage coute 2 € ou plus sachant que c'est une aubergine (Avec justification).
- 3) (1 point) Calculer la probabilité que le fruit/légume du sondage soit un fruit sachant qu'il coute 3 € ou moins (Avec justification).
- 4) (1 point) Calculer l'espérance conditionnelle du prix d'un fruit/légume du sondage sachant que c'est une courgette (Avec justification).
- 5) (1 point) Calculer la variance conditionnelle du prix d'un fruit/légume du sondage sachant qu'on est un légume et que notre prix est pair (Avec justification).

### Exercice 2

On considère un ensemble de points  $v_1, \dots, v_N \in \mathbb{R}^d$  ( $d$  étant l'entier correspondant à la dimension des points). On définit alors la *variance empirique* comme

$$E(v_1, \dots, v_N) = \frac{1}{N} \sum_{i=1}^N (v_i - \hat{\mu})^2$$

où

$$\hat{\mu} = \frac{1}{N} \sum_{i=1}^N v_i.$$

La variance empirique est utilisée comme une mesure de non-uniformité dans les données.

- 1) (2 points) Montrer que la variance empirique est  $\geq 0$  et qu'elle est égale à 0 si et seulement si  $v_1 = \dots = v_N$ .
- 2) (1 point) Justifier à l'aide d'une phrase pourquoi la variance empirique est une bonne mesure de non-cohésion.

- 3) (1 point) Calculer  $E(1, 2, 3, 2, 3, 2, 2, 1, 2)$ .

On a un jeu de données défini par ce tableau.

$i$	1	2	3	4	5	6	7	8
$x^{(i)}$	(0.1, 0.1)	(0.2, 0.2)	(0.7, 0.2)	(0.8, 0.3)	(0.2, 0.6)	(0.3, 0.7)	(0.7, 0.7)	(0.8, 0.9)
$y_i$	-1	-3	-4	-3	2	4	2	3

On note  $x^{(i)} = (x_1^{(i)}, x_2^{(i)})$  pour  $i = 1, \dots, 8$ .

- 4) (1 point) Représenter ces points sur un dessin en numérotant bien chacun
- 5) (2 points) Calculer  $E(y_1, \dots, y_8)$ .

On cherche à séparer les données  $(y_1, \dots, y_8)$  en 2 groupes. Le groupe 1 sera celui des  $y_i$  pour lesquels  $x_1^{(i)} \leq t$  avec  $t = 0,5$  et le groupe 2 sera celui des autres  $y_i$ . On note  $u_1, \dots, u_k$  les éléments du groupe 1 et  $v_1, \dots, v_\ell$  les

éléments du groupe 2 (on a  $k + \ell = 8$ ). Calculer

$$\frac{k}{8}E(u_1, \dots, u_k) + \frac{\ell}{8}E(v_1, \dots, v_\ell)$$

qui est la variance empirique moyenne après séparation en 2 groupes. Faire un dessin qui représente cela.

**6)** (1 point) On cherche à nouveau à séparer les données  $(y_1, \dots, y_8)$  en 2 groupes. Cette fois le groupe 1 sera celui des  $y_i$  pour lesquels  $x_2^{(i)} \leq s$  avec  $s = 0,5$  et le groupe 2 sera celui des autres  $y_i$ . On note  $u_1, \dots, u_k$  les éléments du groupe 1 et  $v_1, \dots, v_\ell$  les éléments du groupe 2 (on a  $k + \ell = 8$ ). Calculer

$$\frac{k}{8}E(u_1, \dots, u_k) + \frac{\ell}{8}E(v_1, \dots, v_\ell).$$

Faire un dessin qui représente cela.

**7)** (1 point) Quelle séparation en deux groupes préférez-vous dans une optique de régression supervisée, et pourquoi ?

La construction d'un arbre de régression se fait selon le principe des questions précédentes. La fin de cet exercice décrit l'algorithme, mais il n'y a plus de questions.

— Faire la séparation de la question 2, mais cette fois, trouver la valeur de  $t$  qui minimise la quantité

$$\frac{k}{8}E(u_1, \dots, u_k) + \frac{\ell}{8}E(v_1, \dots, v_\ell)$$

que l'on notera  $e_1$ .

— Ensuite, faire la même chose mais selon la question 3 en trouvant la valeur de  $s$  qui minimise la quantité

$$\frac{k}{8}E(u_1, \dots, u_k) + \frac{\ell}{8}E(v_1, \dots, v_\ell)$$

que l'on notera  $e_2$ .

— Garder celle des deux séparations qui correspond à la plus petite valeur entre  $e_1$  et  $e_2$ . Cela revient à diviser le carré  $[0, 1]^2$  en 2 rectangles.

— Dans chacun des deux rectangles faire la même chose que toutes les étapes d'avant (si il y a encore deux classes représentées). A la fin, on a divisé le carré  $[0, 1]^2$  en 3 ou 4 rectangles. Cela correspond aux premières étapes de construction d'un arbre de régression. Dans chacun des rectangles, on classe un nouveau  $x$  selon la moyenne empirique des points qui sont dans ce rectangle.

### Exercice 3

Soit  $(X, Y)$  un couple de variables aléatoires telles que  $X \in \mathbb{R}^d$  un espace de features et  $Y \in \{0, 1\}$  est une variable catégorielle.

Pour une fonction de classification  $g : \mathbb{R}^d \rightarrow \{0, 1\}$ , nous définissons  $L(g) = \mathbb{E}(\mathbb{1}_{g(X) \neq Y})$  le risque théorique de  $g$  pour la perte du 0 – 1.

**1)** (2 points) Si  $g$  et  $g'$  sont deux fonctions de classification, montrer que

$$|L(g) - L(g')| \leq \mathbb{P}(g(X) \neq g'(X)).$$

**2)** (2 points) Si  $g$  est une fonction de classification, montrer que

$$L(g) = \mathbb{E}(\mathbb{1}_{g(X) \neq 1}(2\eta(X) - 1) + (1 - \eta(X)))$$

où  $\eta(x) = \mathbb{E}(Y|X = x) = \mathbb{P}(Y = 1|X = x)$ .

**3)** (2 points) En déduire que si  $g$  et  $g'$  sont deux fonctions de classification,

$$|L(g) - L(g')| = \mathbb{E}(\mathbb{1}_{g(X) \neq g'(X)} |2\eta(X) - 1|).$$